

Capsule 10

Objectifs de la capsule

À la fin de cette capsule, vous serez en mesure de:

1. Comprendre le principe d'un **test non paramétrique** sur les **rangs**,
2. Connaître les tests non-paramétriques de comparaison de moyennes disponibles dans R,
3. Appliquer ces tests à vos données.

Les méthodes utilisées dans ce script sont avancées, mais chacune peut être facilement comprise en étudiant l'aide relative aux fonctions utilisées (voir capsule #3).

Capsule vidéo

<https://youtu.be/E4R5Jh4L3wU>

Exercices

i Note

Veuillez noter qu'il est possible d'avoir plus d'une bonne réponse par question. Vous pouvez reprendre chaque exercice grâce aux boutons "Start Over". Le bouton "Indice" est là pour être utilisé!

i Note

i Note


i Note

i Note

Voici un jeu de données. Il s'agit du débit annuel mesuré à Aswan le long du cours du Nil (unité = $10^8 m^{-3}$) de 1871 à 1970. Nous voulons comparer les débits moyens entre les périodes 1890-1899 et 1960-1969.

```
data(Nile)
plot(Nile, xlab = "Année", ylab = "Débit annuel du Nil (10^8 m^-3)")

## Identifier les deux périodes
i <- time(Nile) > 1889 & time(Nile) < 1900
j <- time(Nile) > 1959 & time(Nile) < 1970
N1 <- ts(Nile[i], start = 1890, end = 1899, frequency = 1)
N2 <- ts(Nile[j], start = 1960, end = 1969, frequency = 1)
lines(N1, lwd = 3, col = "red")
lines(N2, lwd = 3, col = "blue")
```



Faites deux histogrammes : des échantillons N1 (débit pour la période 1890-1899) et N2 (débit de 1960 à 1969).

```
{webr}
#| autorun: false
```


💡 Indice

Vous pouvez utiliser la fonction `hist()` pour créer des histogrammes.

 Solution


```
hist(N1)
```

Histogram of N1



```
hist(N2)
```

Histogram of N2



Pensez-vous que leur distribution de fréquence suive une loi Normale ? Demandez vous si les distributions sont unimodales, symétriques et sans valeurs extrêmes (loin de la moyenne). Faites le test de Shapiro avec la fonction `shapiro.test()` pour le vérifier. Qu'en est-il d'après le test ?

```
{webr}  
#| autorun: false
```

⚠ Solution

```
shapiro.test(N1)
```

Shapiro-Wilk normality test

```
data:  N1  
W = 0.82834, p-value = 0.03196
```

```
shapiro.test(N2)
```

Shapiro-Wilk normality test

```
data:  N2  
W = 0.91778, p-value = 0.3388
```

Faites le test statistique approprié pour comparer les débits moyens des deux périodes.

```
{webr}  
#| autorun: false
```

💡 Indice

Vous pourriez utiliser `?wilcox.test`.

⚠ Solution

```
wilcox.test(N1, N2, exact = FALSE)
```

Wilcoxon rank sum test with continuity correction

data: N1 and N2

W = 88, p-value = 0.004571

alternative hypothesis: true location shift is not equal to 0

Matériel accompagnateur

Charger les données pour l'analyse

i Note

Tapez “airquality” dans l’aide de R pour en savoir plus (voir capsule #1).

Il s’agit d’un jeu de données fourni avec R et qui comprend des mesures relatives à la qualité de l’air de New York de mai à septembre 1973. On va d’abord charger le jeu de données, puis le rendre accessible en premier plan dans la mémoire de R :

```
data("airquality")
```


Tests paramétriques, non-paramétriques et notion de rang.

Un test **paramétrique** est appelé ainsi parce qu’il utilise les paramètres mathématiques des distributions de fréquence des valeurs des échantillons testés. Par exemple, lorsque la distribution des valeurs d’un échantillon correspond à une **distribution Normale**, toute l’information contenue dans ces valeurs peut être **résumée par deux paramètres** mathématiques qui définissent l’équation de cette distribution :

1. La variable de **centralité** “moyenne”,
2. La variable de **dispersion** “variance” (= écart-type²).

Nous pouvons illustrer ce principe avec le graphique ci-dessous :

Vents enregistrés en juillet 1973



Ici la correspondance visuelle n'est pas parfaite; malgré tout un test formel comme le `shapiro.test()` ne trouve pas de différence significative entre la distribution des valeurs de vent échantillonnées et une distribution normale (p -value > seuil alpha de 0.05) :


```
shapiro.test(airquality$Wind[M7])
```

Shapiro-Wilk normality test

```
data:  airquality$Wind[M7]  
W = 0.95003, p-value = 0.1564
```

Ceci permet de **résumer l'information** contenue dans ces données avec **seulement les paramètres de moyenne et d'écart-type**, et de faire des **tests paramétriques** sur ces données. Toutefois, les valeurs des échantillons ne peuvent pas toujours être assimilées à des distributions de fréquences dont les propriétés mathématiques conviennent (ni conformes ni transformables) : valeurs aléatoires uniformes, présence de valeurs extrêmes (*outliers*), valeurs regroupées autour de plusieurs modes, etc. Tous ces cas de figure et bien d'autres existent dans les systèmes naturels que nous étudions ! Prenons comme exemple dans le même jeu de données la distribution des valeurs d'insolation du mois de juillet :

Insolation en juillet 1973



Cette fois-ci, les données **ne** correspondent **pas** à une distribution normale, comme le confirme le test de Shapiro-Wilk (p -value $\ll$ seuil $\alpha = 0.05$, rejet de l'hypothèse nulle) :

```
shapiro.test(airquality$Solar.R[M7])
```

Shapiro-Wilk normality test

data: airquality\$Solar.R[M7]
W = 0.86304, p-value = 0.0009729

⚠ Warning

La solution est alors de **ne pas** travailler sur les **valeurs** échantillonnées, mais sur leurs **rangs** dans l'échantillon.

Pour mieux comprendre, regardons le tableau suivant qui représente les mêmes données brutes et leur **rang** dans la distribution associée :

	Insolation	Rang
1	7	1
2	48	2
3	81	3
4	82	4

5	101	5
6	139	6
7	175	8
8	175	8
9	175	8
10	187	10
11	213	11
12	220	12
13	223	13
14	236	14
15	248	15
16	253	16
17	254	17
18	258	18
19	260	19
20	264	20
21	267	21
22	269	22
23	272	23
24	274	24
25	275	25
26	276	26
27	285	27
28	291	28
29	294	29
30	295	30
31	314	31

Warning

Le rang correspond donc tout simplement à la position de chaque valeur par rapport aux autres, lorsqu'on les classe par ordre croissant !

L'avantage des rangs est que les valeurs extrêmes (*outliers*) ou une répartition irrégulière des valeurs n'ont plus d'importance pour le reste des analyses statistiques. Seul compte les positions relatives des valeurs par rapport aux autres auxquelles elles sont comparées. Remarquez ici que certaines valeurs identiques (175) impliquent des rangs identiques (8) qui correspondent à leur position moyenne par rapport aux valeurs immédiatement inférieure et supérieure : ici, au lieu d'avoir la séquence 6, 7, 8, 9, 10... on a 6, 8, 8, 8, 10.

Tests non-paramétriques de comparaison de moyennes

Le but ici est simplement d'utiliser les équivalents non-paramétriques des tests de comparaison de moyennes pour un, deux et plusieurs échantillons sur un jeu de données qui **ne se conforment pas aux conditions d'application du test** reliées à leur distribution.

- Test de **Wilcoxon** / Mann-Whitney : comparaison d'une moyenne d'un échantillon et d'une valeur ou des moyennes de deux échantillons

On peut utiliser le `wilcoxon.test()` pour comparer la moyenne des valeurs d'insolation au mois de juillet à une valeur seuil arbitraire de 200 Ly. Il faut procéder comme pour la fonction `t.test()` en spécifiant une valeur à l'argument (option) `mu =` :

```
# Test
wilcoxon.test(airquality$Solar.R[M7], mu = 200)
```

Wilcoxon signed rank test with continuity correction


```
data: airquality$Solar.R[M7]
V = 318.5, p-value = 0.1701
alternative hypothesis: true location is not equal to 200
```

Vous n'avez bien sûr pas besoin de calculer vous-même les rangs des valeurs échantillonnées pour effectuer ces tests dans R. Le test de Wilcoxon vérifie l'hypothèse nulle que la distribution des valeurs échantillonnées est symétrique par rapport à μ , autrement dit qu'il y a autant de valeurs dont le rang est supérieur que de valeurs dont le rang est inférieur à μ . Comme le démontre la p -value > seuil $\alpha = 0.05$, ici ce test **ne permet pas de rejeter l'hypothèse nulle**.

On peut également utiliser le `wilcoxon.test()` pour comparer les distributions de deux échantillons. On va maintenant comparer la moyenne des valeurs d'insolation aux mois de juillet et août.

```
# Indice pour le mois d'août
M8 <- airquality$Month == 8

# Boxplot
boxplot(airquality$Solar.R[M7 | M8] ~ airquality$Month[M7 | M8], xlab = "Mois
de l'année", ylab = "Insolation (Langley)")
```



```
# Test
wilcox.test(airquality$Solar.R[M7], airquality$Solar.R[M8])
```

Wilcoxon rank sum test with continuity correction

```
data: airquality$Solar.R[M7] and airquality$Solar.R[M8]
W = 606, p-value = 0.009229
alternative hypothesis: true location shift is not equal to 0
```

Dans ce cas de figure, le test de Wilcoxon vérifie si la différence entre les moyennes des rangs est significativement différente de 0. Ce n'est pas le cas ici, comme le démontre la p -value $< \alpha$ seuil $\alpha = 0.05$ qui permet de **rejeter l'hypothèse nulle** qui est qu'il n'y a pas de différence entre les moyennes des rangs.

- Test de **Kruskal-Wallis** pour la comparaison des moyennes de plusieurs (> 2) échantillons


Comme pour les comparaisons de moyennes de deux groupes, il existe un équivalent non-paramétrique à l'ANOVA pour comparer les moyennes de plusieurs groupes : le test de Kruskal-Wallis, qui est essentiellement une extension du test de Wilcoxon. Nous allons utiliser le `kruskal.test()` pour comparer la moyenne des valeurs d'insolation des mois de mai à septembre

```
# Boxplot
boxplot(
  Solar.R ~ Month,
```

```

xlab = "Mois de l'année",
ylab = "Insolation (Langley)",
col = c("grey", "white", "white", "white", "white"),
data = airquality
)

```



```

# Test
kruskal.test(Solar.R ~ Month, data = airquality)

```

Kruskal-Wallis rank sum test

```

data: Solar.R by Month
Kruskal-Wallis chi-squared = 7.9246, df = 4, p-value = 0.09438

```

On remarque que malgré notre résultat précédent et l'allure des distributions des valeurs d'insolation échantillonnées chaque mois, le test ne permet pas de rejeter l'hypothèse nulle; **il ne détecte pas de différence significative entre les mois de mai à septembre** lorsqu'il analyse tous les groupes ensemble. Ceci est essentiellement dû à la **grande dispersion des valeurs pour le mois de mai** (grisé dans le boxplot). Si nous reprenons l'analyse en **excluant les données du mois de mai**, nous trouvons alors :

```

# Indice pour le mois de mai
M5 <- airquality$Month == 5

```

```
# Test  
kruskal.test(Solar.R[!M5] ~ Month[!M5], data = airquality)
```

```
Kruskal-Wallis rank sum test  
  
data: Solar.R[!M5] by Month[!M5]  
Kruskal-Wallis chi-squared = 9.0912, df = 3, p-value = 0.0281
```

Cette fois-ci le test confirme ce qu'il semblait en observant les données, à savoir **qu'au moins une des valeurs de rang moyen est différente des autres**.

! Important

Ce test, tout comme sa contrepartie paramétrique l'ANOVA, n'indique pas **quel(s)** groupe(s) se distingue(nt) des autres !

Si on veut poursuivre l'analyse, il faut alors faire des tests de comparaisons de moyenne deux à deux non-paramétriques de Wilcoxon avec une **correction de Bonferroni** (par exemple) de la valeur seuil alpha de rejet de l'hypothèse nulle pour éviter l'inflation de l'erreur de type I (voir capsule #8).